



Machine Learning

Analyse Comportementale Clientèle Retail avec Machine Learning

Exploration, Préparation, ACP, Modélisation et Recommandations Métier

Présenté par :
Ahmed Jallouli

Contexte :
**Analyse de clients e-
commerce**

Contexte et objectifs du projet

Contexte

- Entreprise e-commerce de cadeaux
- Besoin : mieux comprendre les clients
- Objectif : améliorer les décisions marketing

Objectifs métier

- Comprendre les comportements d'achat
- Identifier les clients à risque de churn
- Segmenter la clientèle
- Estimer la valeur client (MonetaryTotal)
- Proposer des actions marketing ciblées



Contexte et objectifs du projet

Objectifs pédagogiques

- Exploration des données
- Préparation et preprocessing
- Réduction de dimension (ACP / PCA)
- Modélisation :
- Clustering
- Classification
- Régression
- Évaluation et interprétation
- Préparation au déploiement (Flask)



Présentation de la dataset

Dataset :

- 4 372 clients
- 52 variables
- Données :
 - Transactionnelles
 - Comportementales
 - Démographiques
 - Catégorielles

Exemples de variables :

- Recency → jours depuis le dernier achat
- Frequency → nombre de commandes
- MonetaryTotal → montant total dépensé
- Age → âge du client
- SatisfactionScore → satisfaction client
- Churn → départ du client
- RFMSegment, CustomerType, Region, Account Status

Variable cible principale :

- Churn = 0 → client fidèle
- Churn = 1 → client parti

Exploration des données

Objectif : Comprendre la structure et la qualité des données avant la modélisation

Analyses réalisées :

- Dimensions du dataset
- Types des variables
- Valeurs manquantes
- Valeurs aberrantes
- Distribution de Churn
- Corrélations entre variables
- Analyse des variables catégorielles



Exploration des données

Objectif : Comprendre la structure et la qualité des données avant la modélisation

Problèmes détectés :

- Valeurs manquantes dans Age et AvgDaysBetweenPurchases
- Valeurs aberrantes dans SupportTicketsCount
- Valeurs aberrantes dans SatisfactionScore
- NewsletterSubscribed constante → peu informative
- RegistrationDate à parser (feature temporelle)
- LastLoginIP à transformer (feature engineering)
- Risque de data leakage avec certaines variables



Préparation & Preprocessing

Objectif : Transformer les données brutes en données exploitables par les modèles ML

Traitements appliqués :

- Correction des valeurs aberrantes
- Imputation des valeurs manquantes
- Parsing de RegistrationDate
- Feature engineering sur LastLoginIP
- Suppression des colonnes inutiles
- Suppression de ChurnRiskCategory (éviter le data leakage)
- Encodage One-Hot des variables catégorielles
- Standardisation des variables numériques
- Split train/test stratifié

Sorties générées :

- Dataset nettoyée
- Données train/test préparées
- Preprocessor sauvegardé (.joblib)

Transformation — ACP / PCA

Objectif : Réduire la dimension du dataset tout en conservant l'information principale

Pourquoi utiliser PCA ?

- Réduire le nombre de features
- Faciliter la visualisation en 2D
- Réduire le bruit dans les données
- Accélérer certains modèles
- Comparer les performances avec et sans PCA

Travail réalisé

- Application de PCA sur les données prétraitées
- Analyse de la variance expliquée
- Création d'une version avec 80% de variance conservée
- Visualisation des clients en 2D selon Churn

Sorties générées

- X_train_pca_80.csv
- X_test_pca_80.csv
- pca_80.joblib

Clustering — Segmentation des clients

Objectif : Regrouper les clients selon leurs comportements (sans variable cible)

Méthodes :


- K-Means
- Méthode du coude
- Silhouette score

Choix du nombre de clusters :

- $k = 3$

Justification :

- $k = 2 \rightarrow$ meilleur score mais segmentation trop simple
- $k = 3 \rightarrow$ bon compromis (qualité + interprétation métier)
- $k \geq 4 \rightarrow$ dégradation du score silhouette



Clustering — Segmentation des clients


Objectif : Regrouper les clients selon leurs comportements (sans variable cible)

Résultats :

- Cluster 0 → 33.39% churn
- Cluster 1 → 0.00% churn
- Cluster 2 → 50.00% churn

Interprétation :

- Cluster 1 → clients fidèles
- Cluster 0 → clients standards (risque moyen)
- Cluster 2 → clients à haut risque



Classification — Prédiction du churn

Objectif : Prédire si un client risque de quitter l'entreprise

Variable cible : Churn (0 = fidèle, 1 = parti)

Modèles testés :

- Logistic Regression (avec/sans PCA)
- Random Forest (avec/sans PCA)

Métriques utilisées :

- Accuracy
- Precision
- Recall
- F1-score
- ROC-AUC

Résultat principal :

Random Forest sans PCA → meilleur modèle

Classification — Prédiction du churn

Résultats comparatifs

Modèle	Accuracy	Precision	Recall	F1-score	ROC-AUC
Logistic Regression (sans PCA)	0.998	0.997	0.997	0.997	0.999
Random Forest (sans PCA)	1.000	1.000	1.000	1.000	1.000
Logistic Regression (avec PCA)	0.965	0.945	0.948	0.947	0.993
Random Forest (avec PCA)	0.960	0.992	0.887	0.936	0.987

Remarque importante

Scores très élevés → variables très corrélées au churn

Régression — Prédiction de MonetaryTotal

Objectif : Prédire si un client risque de quitter l'entreprise


Variable cible : MonetaryTotal

Modèles testés :

- Linear Regression
- Random Forest Regressor

Métriques utilisées :

- MAE
- RMSE
- R^2



Classification — Prédiction du churn

Résultats comparatifs

Modèle	MAE	RMSE	R ²
Linear Regression	840.51	6603.90	0.661
Random Forest Regressor	741.02	7342.25	0.581

Interprétation:

- Random Forest → meilleur MAE
- Linear Regression → meilleur RMSE et meilleur R²
- Modèle retenu : Linear Regression

Classification — Prédiction du churn

Résultats comparatifs

Modèle	MAE	RMSE	R ²
Linear Regression	840.51	6603.90	0.661
Random Forest Regressor	741.02	7342.25	0.581

Interprétation:

- Random Forest → meilleur MAE
- Linear Regression → meilleur RMSE et meilleur R²
- Modèle retenu : Linear Regression

Évaluation globale & Recommandations

Synthèse :

- Clustering → segmentation des clients
- Classification → prédiction du churn
- Régression → estimation de la valeur client

Recommandations métier

- Cibler le cluster 2 (haut risque) → campagnes de rétention
- Offres personnalisées pour clients à risque
- Valoriser le cluster 1 → programmes VIP / fidélité
- Utiliser la classification pour anticiper le churn
- Utiliser la régression pour prioriser les clients à forte valeur
- Surveiller les variables liées au churn (éviter biais / leakage)

Évaluation globale & Recommendations

Synthèse :


- Clustering → segmentation des clients
- Classification → prédiction du churn
- Régression → estimation de la valeur client

Recommendations métier

- Cibler le cluster 2 (haut risque) → campagnes de rétention
- Offres personnalisées pour clients à risque
- Valoriser le cluster 1 → programmes VIP / fidélité
- Utiliser la classification pour anticiper le churn
- Utiliser la régression pour prioriser les clients à forte valeur
- Surveiller les variables liées au churn (éviter biais / leakage)

Conclusion

- Projet couvrant toute la chaîne ML :
- exploration → préparation → ACP → modélisation → évaluation
- Résultats clés :
 - Segmentation des clients
 - Prédiction du churn
 - Estimation de la valeur client
- Impact métier :
 - Amélioration de la rétention
 - Marketing ciblé
 - Priorisation des clients à forte valeur
- Limites :
 - Risque de data leakage
 - Influence des outliers



Le projet montre comment transformer les données clients en décisions marketing exploitables.

Merci Pour Votre
Attention

