

Atelier Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Analyse Comportementale Clientèle Retail avec Machine Learning

Atelier Pratique : E-commerce de Cadeaux

Module : Machine Learning

Établissement : ENIS / GI2

Année universitaire : 2025–2026

Réalisé par : Ahmed Jallouli

Encadré par : [Fadoua Drira]

Exploration – Préparation – ACP – Modélisation – Évaluation – Déploiement

Résumé

Ce projet porte sur l'analyse comportementale de clients d'une entreprise e-commerce spécialisée dans les cadeaux. L'objectif est d'exploiter une base de données client afin de comprendre les comportements d'achat, segmenter la clientèle, prédire le churn et estimer la valeur monétaire des clients.

Le travail suit une chaîne complète de Machine Learning : exploration des données, nettoyage, preprocessing, réduction de dimension par ACP, modélisation, évaluation et préparation au déploiement avec Flask. Trois approches de modélisation sont appliquées : le clustering, la classification et la régression.

Les résultats obtenus permettent de proposer des recommandations marketing exploitables pour améliorer la rétention client, identifier les segments à risque et optimiser les campagnes ciblées. Ainsi, ce projet montre comment les données clients peuvent être transformées en décisions marketing concrètes et utiles pour l'entreprise.

Table des matières

1	Introduction générale	3
1.1	Contexte du projet	3
1.2	Problématique	3
1.3	Objectifs du projet	3
1.3.1	Objectifs métier	3
1.3.2	Objectifs pédagogiques	3
2	Présentation de la dataset	4
2.1	Description générale	4
2.2	Types de variables	4
2.2.1	Variables transactionnelles	4
2.2.2	Variables comportementales	4
2.2.3	Variables démographiques	5
2.2.4	Variables catégorielles métier	5
2.2.5	Variable cible	5
3	Exploration des données	5
3.1	Objectif de l'exploration	5
3.2	Dimensions et types des variables	6
3.3	Analyse des valeurs manquantes	6
3.4	Distribution de la variable cible Churn	7
3.5	Analyse des valeurs aberrantes	8
3.6	Analyse des corrélations	9
3.7	Analyse des variables catégorielles	10

1 Introduction générale

1.1 Contexte du projet

Ce projet s'inscrit dans le cadre d'un atelier pratique de Machine Learning appliqué à l'analyse comportementale de clients retail. Le contexte étudié est celui d'une entreprise e-commerce spécialisée dans la vente de cadeaux. Cette entreprise souhaite mieux comprendre sa clientèle afin d'améliorer ses décisions marketing, personnaliser ses campagnes et optimiser son chiffre d'affaires.

Les principaux enjeux du projet sont les suivants :

- **Churn client** : identifier les clients susceptibles de quitter l'entreprise.
- **Segmentation client** : regrouper les clients selon leurs comportements d'achat.
- **Estimation de la valeur client** : prédire le montant total dépensé par un client.

Ainsi, l'analyse des données clients permet de transformer les informations brutes en connaissances exploitables pour soutenir les décisions marketing.

1.2 Problématique

La problématique principale de ce projet peut être formulée comme suit :

Comment exploiter les données comportementales et transactionnelles des clients afin de prédire leur risque de départ, segmenter la clientèle et proposer des recommandations marketing adaptées ?

1.3 Objectifs du projet

Ce projet poursuit à la fois des objectifs métier liés à l'analyse de la clientèle et des objectifs pédagogiques liés à la mise en œuvre d'une chaîne complète de Machine Learning.

1.3.1 Objectifs métier

Les objectifs métier visent à aider l'entreprise à mieux exploiter ses données clients afin d'améliorer ses décisions marketing. Ils sont les suivants :

- Comprendre les comportements d'achat des clients.
- Identifier les clients à risque de churn.
- Segmenter la clientèle selon les profils comportementaux.
- Estimer la valeur monétaire des clients.
- Proposer des recommandations marketing ciblées.

1.3.2 Objectifs pédagogiques

Les objectifs pédagogiques consistent à appliquer les différentes étapes d'un projet Machine Learning complet :

- Explorer la qualité et la structure des données.
- Nettoyer, encoder et normaliser les features.
- Réduire la dimension des données via l'ACP.
- Appliquer plusieurs approches de modélisation :
 - clustering
 - classification
 - régression
- Évaluer les modèles et interpréter les résultats obtenus.
- Proposer des recommandations métier exploitables.
- Préparer le déploiement du projet à travers une interface Flask.

2 Présentation de la dataset

2.1 Description générale

La dataset utilisée dans ce projet regroupe des informations relatives aux clients d'une entreprise e-commerce spécialisée dans la vente de cadeaux. Elle contient un ensemble de données transactionnelles, comportementales, démographiques et catégorielles permettant d'analyser le profil des clients et leur comportement d'achat.

La base de données contient :

- **4 372 clients**
- **52 variables**
- chaque ligne représente un client
- chaque colonne décrit une caractéristique ou un comportement du client.

Les variables décrivent principalement :

- le comportement d'achat des clients ;
- les transactions réalisées ;
- le niveau de satisfaction ;
- le profil client ;
- la localisation géographique ;
- le statut de churn.

Résumé de la dataset : la dataset contient 4 372 observations et 52 variables. Elle permet d'étudier les comportements des clients, de prédire le churn, de segmenter la clientèle et d'estimer la valeur monétaire des clients.

2.2 Types de variables

La dataset contient plusieurs familles de variables permettant de décrire les clients selon différents aspects : transactions, comportements d'achat, profil démographique et informations métier.

2.2.1 Variables transactionnelles

Les variables transactionnelles décrivent l'activité d'achat et les montants dépensés par les clients :

- **Recency** : nombre de jours depuis le dernier achat.
- **Frequency** : nombre de commandes effectuées.
- **MonetaryTotal** : montant total dépensé par le client.
- **MonetaryAvg** : montant moyen dépensé par commande.
- **TotalQuantity** : quantité totale d'articles achetés.

2.2.2 Variables comportementales

Les variables comportementales permettent d'analyser les habitudes d'achat et l'activité des clients :

- **CustomerTenureDays** : ancienneté du client.
- **AvgDaysBetweenPurchases** : délai moyen entre deux achats.
- **WeekendRatio** : proportion des achats effectués le week-end.
- **PreferredDay** : jour préféré d'achat.
- **PreferredHour** : heure préférée d'achat.

2.2.3 Variables démographiques

Les variables démographiques décrivent le profil général du client :

- **Age** : âge du client.
- **Gender** : genre du client.
- **AgeCategory** : catégorie d'âge.
- **Region** : région géographique.
- **Country** : pays du client.

2.2.4 Variables catégorielles métier


Les variables catégorielles métier représentent des informations utiles pour l'analyse marketing :

- **RFMSegment** : segment client selon l'approche RFM.
- **CustomerType** : type de client selon son comportement.
- **SpendingCategory** : catégorie de dépense.
- **LoyaltyLevel** : niveau de fidélité.
- **AccountStatus** : statut du compte client.

2.2.5 Variable cible

La variable cible principale utilisée dans la partie classification est **Churn**. Elle indique si un client a quitté l'entreprise ou non :

- **Churn = 0** : client fidèle.
- **Churn = 1** : client parti.



CustomerID	Recency	Frequency	MonetaryTotal	MonetaryAvg	MonetaryStd	MonetaryMin	MonetaryMax	TotalQuantity	AvgQuantityPerTransaction	MinQuantity	MaxQuantity	CustomerTenureDays	FirstPurchaseDaysAgo	PreferredDayOfWeek	PreferredHour	PreferredMonth	WeekendPurchaseRatio	AvgDaysBetweenPurch
17850	302	35	5288.63	16.950737	13.603662	-30.60	107.25	1693	5.426282	-12	12	71	374	3	9	12	0.000000	0.22
13047	32	18	3079.10	15.709694	11.864789	-15.00	60.00	1355	6.913285	-3	32	342	374	2	13	10	0.198067	1.73
12583	3	18	7187.34	28.634821	23.150132	-60.84	132.80	5009	18.956175	-36	360	370	374	4	12	11	0.953777	1.45
13748	96	5	940.25	33.868071	42.953119	9.36	204.00	439	15.678571	1	80	278	374	0	9	9	0.000000	10.23
15100	330	6	635.10	105.850000	215.988283	-131.40	350.40	58	9.866667	-12	32	43	374	2	9	12	0.000000	8.20

FIGURE 1 – Vue générale de la dataset

3 Exploration des données

3.1 Objectif de l'exploration

L'exploration des données constitue une étape essentielle avant la phase de modélisation. Elle permet de comprendre la structure générale de la dataset, d'analyser la qualité des données et d'identifier les éventuels problèmes pouvant influencer les performances des modèles Machine Learning.

Cette étape vise principalement à :

- analyser les dimensions de la dataset ;
- identifier les types des variables ;
- détecter les valeurs manquantes ;
- repérer les valeurs aberrantes ;
- étudier les distributions des variables ;
- analyser la variable cible **Churn** ;
- étudier les relations et corrélations entre les variables.

Ainsi, l'exploration permet de préparer les décisions nécessaires pour le nettoyage, le preprocessing et la modélisation.

3.2 Dimensions et types des variables

Après le chargement de la dataset, une première analyse de sa structure a été réalisée à l'aide des fonctions `shape` et `info()` de la bibliothèque Pandas.

La dataset contient :

- **4 372 lignes** : chaque ligne représente un client
- **52 colonnes** : chaque colonne représente une variable décrivant le client
- des variables numériques
- des variables catégorielles
- une variable cible : **Churn**.

La fonction `df.info()` a permis d'identifier le type de chaque variable, le nombre de valeurs non nulles et la présence éventuelle de valeurs manquantes. Cette étape est importante pour choisir les traitements adaptés lors du preprocessing, notamment l'imputation, l'encodage et la normalisation.

TABLE 1 – Résumé des types de variables

Type de variable	Nombre	Exemples
Numérique	34	Recency, Frequency, MonetaryTotal
Catégorielle	18	RFMSegment, CustomerType, Region
Cible	1	Churn

3.3 Analyse des valeurs manquantes

L'analyse des valeurs manquantes permet d'identifier les colonnes contenant des données absentes et de définir les stratégies d'imputation adaptées lors du preprocessing.

Dans cette dataset, deux variables présentent principalement des valeurs manquantes :

- **Age** : contient environ **30%** de valeurs manquantes ;
- **AvgDaysBetweenPurchases** : contient un faible pourcentage de valeurs manquantes.

La variable **Age** nécessite donc une attention particulière, car le taux de valeurs manquantes est relativement important. Ces valeurs seront traitées dans la phase de preprocessing à l'aide d'une stratégie d'imputation adaptée, comme l'imputation par la médiane pour les variables numériques.




FIGURE 2 – Heatmap des valeurs manquantes

3.4 Distribution de la variable cible Churn

La variable cible principale utilisée dans la partie classification est **Churn**. Elle permet d'indiquer si un client a quitté l'entreprise ou s'il est toujours actif.

Les deux classes de la variable cible sont définies comme suit :

- **Churn** = 0 : clients fidèles ;
- **Churn** = 1 : clients partis.

L'analyse de la distribution des classes montre une distribution modérément déséquilibrée entre les clients fidèles et les clients ayant quitté l'entreprise. Cette analyse est importante car un déséquilibre important pourrait influencer les performances des modèles de classification.

La visualisation suivante représente la répartition des deux classes de la variable **Churn**.




FIGURE 3 – Distribution des classes de Churn

3.5 Analyse des valeurs aberrantes

L'analyse des valeurs aberrantes permet d'identifier les données anormales susceptibles d'influencer négativement les performances des modèles Machine Learning.

Deux variables présentent principalement des valeurs incohérentes ou extrêmes :

- **SupportTicketsCount** : présence de valeurs anormales comme -1 et 999
- **SatisfactionScore** : présence de valeurs incohérentes telles que -1, 0 et 99.

Ces valeurs ne correspondent pas à des comportements clients réalistes et doivent être traitées lors de la phase de preprocessing. Les boxplots permettent de visualiser clairement la présence de ces valeurs aberrantes.




FIGURE 4 – Boxplot de SupportTicketsCount

La figure précédente montre la présence de valeurs extrêmes dans la variable **SupportTicketsCount**, notamment les valeurs -1 et 999, qui seront remplacées lors du nettoyage des données.




FIGURE 5 – Boxplot de SatisfactionScore

Le boxplot de **SatisfactionScore** met également en évidence des valeurs incohérentes comme -1, 0 et 99. Ces anomalies seront traitées dans la phase de preprocessing afin d'améliorer la qualité des données.

3.6 Analyse des corrélations

L'analyse des corrélations permet d'étudier les relations entre les variables numériques de la dataset. Cette étape est importante afin d'identifier les variables fortement liées entre elles ainsi que les variables les plus influentes sur la variable cible **Churn**.

L'étude des corrélations permet principalement de :

- analyser les relations entre variables numériques
- identifier les variables les plus corrélées avec **Churn**
- détecter les risques de multicollinéarité
- mieux comprendre les facteurs influençant le départ des clients.

La matrice de corrélation suivante représente les relations entre les différentes variables numériques du dataset.




FIGURE 6 – Matrice de corrélation des variables numériques

Cette matrice permet d'identifier les variables fortement corrélées positivement ou négativement. Des corrélations très élevées entre certaines variables peuvent indiquer un risque de multicollinéarité, ce qui peut influencer certains modèles de Machine Learning.

La figure suivante présente les corrélations entre les variables numériques et la variable cible **Churn**.




FIGURE 7 – Corrélations des variables numériques avec Churn

Cette analyse permet d'identifier les variables ayant le plus d'impact sur le churn des clients. Les variables présentant des corrélations importantes avec **Churn** peuvent être particulièrement utiles pour la phase de classification.

3.7 Analyse des variables catégorielles

L'analyse des variables catégorielles permet d'étudier la relation entre les différentes catégories clients et la variable cible **Churn**. Cette étape est importante pour identifier les segments ou statuts clients présentant un risque de départ plus élevé.

Les variables analysées incluent notamment :

- **RFMSegment** : segment client selon l'approche RFM
- **CustomerType** : type de client selon son comportement
- **AccountStatus** : statut du compte client.

La figure suivante présente le taux de churn selon les différentes catégories de la variable **RFMSegment**.




FIGURE 8 – Taux de churn par RFMSegment

La variable **RFMSegment** permet d'identifier les clients selon leur récence, fréquence et montant d'achat. Certains segments peuvent présenter un risque de churn plus élevé, notamment les clients dormants ou peu actifs.

La figure suivante présente le taux de churn selon la variable **CustomerType**.




FIGURE 9 – Taux de churn par CustomerType

L'analyse de **CustomerType** permet d'observer si certains profils comportementaux sont davantage associés au churn. Par exemple, les clients perdus ou occasionnels peuvent présenter un risque plus important que les clients réguliers.

La figure suivante présente le taux de churn selon le statut du compte client.




FIGURE 10 – Taux de churn par AccountStatus

La variable `AccountStatus` peut être fortement liée à la variable cible, car certains statuts de compte peuvent indiquer directement ou indirectement un départ du client.

Remarque importante : Certaines variables catégorielles présentent une relation très forte avec la variable cible `Churn`. Cela nécessite une vigilance particulière afin d'éviter un risque de *data leakage* ou une interprétation trop optimiste des performances des modèles.