

Atelier Machine Learning

Analyse Comportementale Clientèle Retail

COMPTE RENDU

Analyse Comportementale Clientèle Retail avec Machine Learning

Atelier Pratique : E-commerce de Cadeaux

Module : Machine Learning

Établissement : ENIS / GI2

Année universitaire : 2025–2026

Réalisé par : Ahmed Jallouli

Encadré par : Fadoua Drira

Exploration – Préparation – ACP – Modélisation – Évaluation – Déploiement

Résumé

Ce projet porte sur l'analyse comportementale de clients d'une entreprise e-commerce spécialisée dans les cadeaux. L'objectif est d'exploiter une base de données client afin de comprendre les comportements d'achat, segmenter la clientèle, prédire le churn et estimer la valeur monétaire des clients.

Le travail suit une chaîne complète de Machine Learning : exploration des données, nettoyage, preprocessing, réduction de dimension par ACP, modélisation, évaluation et préparation au déploiement avec Flask. Trois approches de modélisation sont appliquées : le clustering, la classification et la régression.

Les résultats obtenus permettent de proposer des recommandations marketing exploitables pour améliorer la rétention client, identifier les segments à risque et optimiser les campagnes ciblées. Ainsi, ce projet montre comment les données clients peuvent être transformées en décisions marketing concrètes et utiles pour l'entreprise.

Table des matières

1	Introduction générale	4
1.1	Contexte du projet	4
1.2	Problématique	4
1.3	Objectifs du projet	4
1.3.1	Objectifs métier	4
1.3.2	Objectifs pédagogiques	4
2	Présentation de la dataset	5
2.1	Description générale	5
2.2	Types de variables	5
2.2.1	Variables transactionnelles	5
2.2.2	Variables comportementales	5
2.2.3	Variables démographiques	6
2.2.4	Variables catégorielles métier	6
2.2.5	Variable cible	6
3	Exploration des données	6
3.1	Objectif de l'exploration	6
3.2	Dimensions et types des variables	7
3.3	Analyse des valeurs manquantes	7
3.4	Distribution de la variable cible Churn	8
3.5	Analyse des valeurs aberrantes	9
3.6	Analyse des corrélations	10
3.7	Analyse des variables catégorielles	11
4	Préparation et preprocessing des données	13
4.1	Objectif du preprocessing	13
4.2	Traitement des valeurs aberrantes	14
4.3	Traitement des valeurs manquantes	14
4.4	Transformation des dates	15
4.5	Feature engineering sur l'adresse IP	15
4.6	Suppression des colonnes inutiles ou risquées	16
4.7	Encodage et normalisation	16
4.8	Split train/test	17
5	Transformation par ACP / PCA	17
5.1	Objectif de l'ACP	17
5.2	Application de PCA	18
5.3	Analyse de la variance expliquée	18
6	Modélisation	20
6.1	Clustering : segmentation des clients	20
6.1.1	Objectif	20
6.1.2	Méthode utilisée	21
6.1.3	Choix du nombre de clusters	21
6.1.4	Résultats du clustering	23
6.2	Classification : prédiction du churn	24
6.2.1	Objectif	24
6.2.2	Modèles testés	24
6.2.3	Métriques utilisées	25
6.2.4	Résultats	25
6.2.5	Interprétation	26

6.3	Régression : prédiction de MonetaryTotal	26
6.3.1	Objectif	26
6.3.2	Modèles testés	27
6.3.3	Métriques utilisées	27
6.3.4	Résultats	27
6.3.5	Interprétation	29
7	Évaluation globale et recommandations métier	29
7.1	Synthèse des résultats	29
7.2	Recommandations métier	29
7.2.1	Recommandation 1 : Cibler les clients à haut risque	30
7.2.2	Recommandation 2 : Valoriser les clients fidèles	30
7.2.3	Recommandation 3 : Utiliser la classification pour anticiper le churn	30
7.2.4	Recommandation 4 : Utiliser la régression pour prioriser la valeur client	30
7.2.5	Recommandation 5 : Surveiller le data leakage	30
8	Limites du projet	31
9	Conclusion générale	31

1 Introduction générale

1.1 Contexte du projet

Ce projet s'inscrit dans le cadre d'un atelier pratique de Machine Learning appliqué à l'analyse comportementale de clients retail. Le contexte étudié est celui d'une entreprise e-commerce spécialisée dans la vente de cadeaux. Cette entreprise souhaite mieux comprendre sa clientèle afin d'améliorer ses décisions marketing, personnaliser ses campagnes et optimiser son chiffre d'affaires.

Les principaux enjeux du projet sont les suivants :

- **Churn client** : identifier les clients susceptibles de quitter l'entreprise.
- **Segmentation client** : regrouper les clients selon leurs comportements d'achat.
- **Estimation de la valeur client** : prédire le montant total dépensé par un client.

Ainsi, l'analyse des données clients permet de transformer les informations brutes en connaissances exploitables pour soutenir les décisions marketing.

1.2 Problématique

La problématique principale de ce projet peut être formulée comme suit :

Comment exploiter les données comportementales et transactionnelles des clients afin de prédire leur risque de départ, segmenter la clientèle et proposer des recommandations marketing adaptées ?

1.3 Objectifs du projet

Ce projet poursuit à la fois des objectifs métier liés à l'analyse de la clientèle et des objectifs pédagogiques liés à la mise en œuvre d'une chaîne complète de Machine Learning.

1.3.1 Objectifs métier

Les objectifs métier visent à aider l'entreprise à mieux exploiter ses données clients afin d'améliorer ses décisions marketing. Ils sont les suivants :

- Comprendre les comportements d'achat des clients.
- Identifier les clients à risque de churn.
- Segmenter la clientèle selon les profils comportementaux.
- Estimer la valeur monétaire des clients.
- Proposer des recommandations marketing ciblées.

1.3.2 Objectifs pédagogiques

Les objectifs pédagogiques consistent à appliquer les différentes étapes d'un projet Machine Learning complet :

- Explorer la qualité et la structure des données.
- Nettoyer, encoder et normaliser les features.
- Réduire la dimension des données via l'ACP.
- Appliquer plusieurs approches de modélisation :
 - clustering
 - classification
 - régression
- Évaluer les modèles et interpréter les résultats obtenus.
- Proposer des recommandations métier exploitables.
- Préparer le déploiement du projet à travers une interface Flask.

2 Présentation de la dataset

2.1 Description générale

La dataset utilisée dans ce projet regroupe des informations relatives aux clients d'une entreprise e-commerce spécialisée dans la vente de cadeaux. Elle contient un ensemble de données transactionnelles, comportementales, démographiques et catégorielles permettant d'analyser le profil des clients et leur comportement d'achat.

La base de données contient :

- **4 372 clients**
- **52 variables**
- chaque ligne représente un client
- chaque colonne décrit une caractéristique ou un comportement du client.

Les variables décrivent principalement :

- le comportement d'achat des clients ;
- les transactions réalisées ;
- le niveau de satisfaction ;
- le profil client ;
- la localisation géographique ;
- le statut de churn.

Résumé de la dataset : la dataset contient 4 372 observations et 52 variables. Elle permet d'étudier les comportements des clients, de prédire le churn, de segmenter la clientèle et d'estimer la valeur monétaire des clients.

2.2 Types de variables

La dataset contient plusieurs familles de variables permettant de décrire les clients selon différents aspects : transactions, comportements d'achat, profil démographique et informations métier.

2.2.1 Variables transactionnelles

Les variables transactionnelles décrivent l'activité d'achat et les montants dépensés par les clients :

- **Recency** : nombre de jours depuis le dernier achat.
- **Frequency** : nombre de commandes effectuées.
- **MonetaryTotal** : montant total dépensé par le client.
- **MonetaryAvg** : montant moyen dépensé par commande.
- **TotalQuantity** : quantité totale d'articles achetés.

2.2.2 Variables comportementales

Les variables comportementales permettent d'analyser les habitudes d'achat et l'activité des clients :

- **CustomerTenureDays** : ancienneté du client.
- **AvgDaysBetweenPurchases** : délai moyen entre deux achats.
- **WeekendRatio** : proportion des achats effectués le week-end.
- **PreferredDay** : jour préféré d'achat.
- **PreferredHour** : heure préférée d'achat.

2.2.3 Variables démographiques

Les variables démographiques décrivent le profil général du client :

- **Age** : âge du client.
- **Gender** : genre du client.
- **AgeCategory** : catégorie d'âge.
- **Region** : région géographique.
- **Country** : pays du client.

2.2.4 Variables catégorielles métier


Les variables catégorielles métier représentent des informations utiles pour l'analyse marketing :

- **RFMSegment** : segment client selon l'approche RFM.
- **CustomerType** : type de client selon son comportement.
- **SpendingCategory** : catégorie de dépense.
- **LoyaltyLevel** : niveau de fidélité.
- **AccountStatus** : statut du compte client.

2.2.5 Variable cible

La variable cible principale utilisée dans la partie classification est **Churn**. Elle indique si un client a quitté l'entreprise ou non :

- **Churn = 0** : client fidèle.
- **Churn = 1** : client parti.



CustomerID	Recency	Frequency	MonetaryTotal	MonetaryAvg	MonetaryStd	MonetaryMin	MonetaryMax	TotalQuantity	AvgQuantityPerTransaction	MinQuantity	MaxQuantity	CustomerLifetimeDays	FirstPurchaseDaysAgo	PreferredDayOfWeek	PreferredHour	PreferredMonth	WeekendPurchaseRatio	AvgDaysBetweenPurch
17850	302	35	5288.63	16.950737	13.603662	-30.60	107.25	1693	5.426282	-12	12	71	374	3	9	12	0.000000	0.22
13047	32	18	3079.10	15.709694	11.864789	-15.00	60.00	1355	6.913285	-3	32	342	374	2	13	10	0.198067	1.73
12583	3	18	7187.34	28.634821	23.150132	-60.84	132.80	5009	18.956175	-36	360	370	374	4	12	11	0.953777	1.45
13748	96	5	940.25	33.868071	42.953119	9.36	204.00	439	15.678571	1	80	278	374	0	9	9	0.000000	10.23
15100	330	6	635.10	105.850000	215.988283	-131.40	350.40	58	9.866667	-12	32	43	374	2	9	12	0.000000	8.20

FIGURE 1 – Vue générale de la dataset

3 Exploration des données

3.1 Objectif de l'exploration

L'exploration des données constitue une étape essentielle avant la phase de modélisation. Elle permet de comprendre la structure générale de la dataset, d'analyser la qualité des données et d'identifier les éventuels problèmes pouvant influencer les performances des modèles Machine Learning.

Cette étape vise principalement à :

- analyser les dimensions de la dataset ;
- identifier les types des variables ;
- détecter les valeurs manquantes ;
- repérer les valeurs aberrantes ;
- étudier les distributions des variables ;
- analyser la variable cible **Churn** ;
- étudier les relations et corrélations entre les variables.

Ainsi, l'exploration permet de préparer les décisions nécessaires pour le nettoyage, le preprocessing et la modélisation.

3.2 Dimensions et types des variables

Après le chargement de la dataset, une première analyse de sa structure a été réalisée à l'aide des fonctions `shape` et `info()` de la bibliothèque Pandas.

La dataset contient :

- **4 372 lignes** : chaque ligne représente un client
- **52 colonnes** : chaque colonne représente une variable décrivant le client
- des variables numériques
- des variables catégorielles
- une variable cible : **Churn**.

La fonction `df.info()` a permis d'identifier le type de chaque variable, le nombre de valeurs non nulles et la présence éventuelle de valeurs manquantes. Cette étape est importante pour choisir les traitements adaptés lors du preprocessing, notamment l'imputation, l'encodage et la normalisation.

TABLE 1 – Résumé des types de variables

Type de variable	Nombre	Exemples
Numérique	34	Recency, Frequency, MonetaryTotal
Catégorielle	18	RFMSegment, CustomerType, Region
Cible	1	Churn

3.3 Analyse des valeurs manquantes

L'analyse des valeurs manquantes permet d'identifier les colonnes contenant des données absentes et de définir les stratégies d'imputation adaptées lors du preprocessing.

Dans cette dataset, deux variables présentent principalement des valeurs manquantes :

- **Age** : contient environ **30%** de valeurs manquantes ;
- **AvgDaysBetweenPurchases** : contient un faible pourcentage de valeurs manquantes.

La variable **Age** nécessite donc une attention particulière, car le taux de valeurs manquantes est relativement important. Ces valeurs seront traitées dans la phase de preprocessing à l'aide d'une stratégie d'imputation adaptée, comme l'imputation par la médiane pour les variables numériques.




FIGURE 2 – Heatmap des valeurs manquantes

3.4 Distribution de la variable cible Churn

La variable cible principale utilisée dans la partie classification est **Churn**. Elle permet d'indiquer si un client a quitté l'entreprise ou s'il est toujours actif.

Les deux classes de la variable cible sont définies comme suit :

- **Churn** = 0 : clients fidèles ;
- **Churn** = 1 : clients partis.

L'analyse de la distribution des classes montre une distribution modérément déséquilibrée entre les clients fidèles et les clients ayant quitté l'entreprise. Cette analyse est importante car un déséquilibre important pourrait influencer les performances des modèles de classification.

La visualisation suivante représente la répartition des deux classes de la variable **Churn**.




FIGURE 3 – Distribution des classes de Churn

3.5 Analyse des valeurs aberrantes

L'analyse des valeurs aberrantes permet d'identifier les données anormales susceptibles d'influencer négativement les performances des modèles Machine Learning.

Deux variables présentent principalement des valeurs incohérentes ou extrêmes :

- **SupportTicketsCount** : présence de valeurs anormales comme -1 et 999
- **SatisfactionScore** : présence de valeurs incohérentes telles que -1, 0 et 99.

Ces valeurs ne correspondent pas à des comportements clients réalistes et doivent être traitées lors de la phase de preprocessing. Les boxplots permettent de visualiser clairement la présence de ces valeurs aberrantes.




FIGURE 4 – Boxplot de SupportTicketsCount

La figure précédente montre la présence de valeurs extrêmes dans la variable **SupportTicketsCount**, notamment les valeurs -1 et 999, qui seront remplacées lors du nettoyage des données.




FIGURE 5 – Boxplot de SatisfactionScore

Le boxplot de **SatisfactionScore** met également en évidence des valeurs incohérentes comme -1, 0 et 99. Ces anomalies seront traitées dans la phase de preprocessing afin d'améliorer la qualité des données.

3.6 Analyse des corrélations

L'analyse des corrélations permet d'étudier les relations entre les variables numériques de la dataset. Cette étape est importante afin d'identifier les variables fortement liées entre elles ainsi que les variables les plus influentes sur la variable cible **Churn**.

L'étude des corrélations permet principalement de :

- analyser les relations entre variables numériques
- identifier les variables les plus corrélées avec **Churn**
- détecter les risques de multicollinéarité
- mieux comprendre les facteurs influençant le départ des clients.

La matrice de corrélation suivante représente les relations entre les différentes variables numériques du dataset.




FIGURE 6 – Matrice de corrélation des variables numériques

Cette matrice permet d'identifier les variables fortement corrélées positivement ou négativement. Des corrélations très élevées entre certaines variables peuvent indiquer un risque de multicollinéarité, ce qui peut influencer certains modèles de Machine Learning.

La figure suivante présente les corrélations entre les variables numériques et la variable cible **Churn**.




FIGURE 7 – Corrélations des variables numériques avec Churn

Cette analyse permet d’identifier les variables ayant le plus d’impact sur le churn des clients. Les variables présentant des corrélations importantes avec **Churn** peuvent être particulièrement utiles pour la phase de classification.

3.7 Analyse des variables catégorielles

L’analyse des variables catégorielles permet d’étudier la relation entre les différentes catégories clients et la variable cible **Churn**. Cette étape est importante pour identifier les segments ou statuts clients présentant un risque de départ plus élevé.

Les variables analysées incluent notamment :

- **RFMSegment** : segment client selon l’approche RFM
- **CustomerType** : type de client selon son comportement
- **AccountStatus** : statut du compte client.

La figure suivante présente le taux de churn selon les différentes catégories de la variable **RFMSegment**.




FIGURE 8 – Taux de churn par RFMSegment

La variable **RFMSegment** permet d'identifier les clients selon leur récence, fréquence et montant d'achat. Certains segments peuvent présenter un risque de churn plus élevé, notamment les clients dormants ou peu actifs.

La figure suivante présente le taux de churn selon la variable **CustomerType**.




FIGURE 9 – Taux de churn par CustomerType

L'analyse de **CustomerType** permet d'observer si certains profils comportementaux sont davantage associés au churn. Par exemple, les clients perdus ou occasionnels peuvent présenter un risque plus important que les clients réguliers.

La figure suivante présente le taux de churn selon le statut du compte client.




FIGURE 10 – Taux de churn par AccountStatus

La variable `AccountStatus` peut être fortement liée à la variable cible, car certains statuts de compte peuvent indiquer directement ou indirectement un départ du client.

Remarque importante : Certaines variables catégorielles présentent une relation très forte avec la variable cible `Churn`. Cela nécessite une vigilance particulière afin d'éviter un risque de *data leakage* ou une interprétation trop optimiste des performances des modèles.

4 Préparation et preprocessing des données

4.1 Objectif du preprocessing

Le preprocessing constitue une étape essentielle dans un projet Machine Learning. Son objectif principal est de transformer les données brutes en données exploitables par les modèles de modélisation.

En pratique, les données réelles contiennent souvent des problèmes de qualité tels que :

- des valeurs manquantes ;
- des valeurs aberrantes ;
- des formats incohérents ;
- des variables catégorielles non exploitables directement ;
- des colonnes inutiles ou redondantes.

Le preprocessing permet donc d'améliorer la qualité des données avant l'entraînement des modèles Machine Learning. Cette étape garantit que les données sont cohérentes, normalisées et adaptées aux algorithmes utilisés.

Les principales opérations réalisées dans cette phase sont :

- le nettoyage des données ;
- le traitement des valeurs manquantes ;
- la correction des valeurs aberrantes ;
- l'encodage des variables catégorielles ;

- la normalisation des variables numériques ;
- la création de nouvelles features ;
- la séparation des données en ensembles d'entraînement et de test.

Ainsi, le preprocessing permet de préparer une base de données fiable et adaptée aux différentes tâches de modélisation du projet.

4.2 Traitement des valeurs aberrantes

L'analyse exploratoire des données a permis d'identifier plusieurs valeurs aberrantes dans certaines variables numériques. Ces valeurs ne correspondent pas à des comportements clients réalistes et peuvent perturber les performances des modèles Machine Learning.

Afin de traiter ces anomalies, les valeurs incohérentes ont été remplacées par des valeurs manquantes (NaN) avant l'étape d'imputation.

Les principales variables concernées sont les suivantes :

- **SupportTicketsCount** : présence des valeurs anormales -1 et 999 ;
- **SatisfactionScore** : présence des valeurs incohérentes -1, 0 et 99.

Ces valeurs ont été considérées comme invalides car elles ne correspondent pas à des mesures réalistes du nombre de tickets support ou du niveau de satisfaction client.

Le traitement appliqué consiste à remplacer ces valeurs par NaN, ce qui permet ensuite de les gérer correctement lors de l'étape d'imputation.

Le code suivant illustre le traitement appliqué :

Listing 1 – Traitement des valeurs aberrantes

```
# SupportTicketsCount
df["SupportTicketsCount"] = df["SupportTicketsCount"].replace(
    [-1, 999],
    np.nan
)

# SatisfactionScore
df["SatisfactionScore"] = df["SatisfactionScore"].replace(
    [-1, 0, 99],
    np.nan
)
```

Cette approche permet d'améliorer la qualité des données et de limiter l'impact des valeurs aberrantes sur les modèles de classification, de clustering et de régression.

4.3 Traitement des valeurs manquantes

Après le remplacement des valeurs aberrantes par NaN, les valeurs manquantes doivent être traitées afin de permettre l'entraînement des modèles Machine Learning. En effet, la plupart des algorithmes ne peuvent pas fonctionner correctement avec des données contenant des valeurs manquantes.

Deux stratégies d'imputation ont été utilisées selon le type de variable :

- **Variables numériques** : imputation par la médiane.
- **Variables catégorielles** : imputation par la modalité la plus fréquente.

L'imputation par la médiane est adaptée aux variables numériques, car elle est moins sensible aux valeurs extrêmes que la moyenne. Pour les variables catégorielles, la modalité la plus fréquente est utilisée afin de remplacer les valeurs absentes par la catégorie la plus représentative.

Stratégie d'imputation appliquée :

- Numérique : remplacement des valeurs manquantes par la médiane.
- Catégorielle : remplacement des valeurs manquantes par la modalité la plus fréquente.

Cette étape permet d'obtenir un dataset complète et exploitable pour les étapes suivantes : encodage, normalisation, ACP et modélisation.

4.4 Transformation des dates

La variable **RegistrationDate** contient la date d'inscription du client sous forme textuelle. Cette variable ne peut pas être utilisée directement par les modèles Machine Learning, car les algorithmes nécessitent des valeurs numériques ou encodées.

La première étape consiste donc à parser la colonne **RegistrationDate**, c'est-à-dire convertir les dates depuis un format texte vers un format date exploitable.

Ensuite, plusieurs nouvelles variables temporelles ont été extraites :

- **RegYear** : année d'inscription du client ;
- **RegMonth** : mois d'inscription du client ;
- **RegDay** : jour d'inscription du client ;
- **RegWeekday** : jour de la semaine correspondant à l'inscription.

Ces nouvelles variables permettent de conserver l'information temporelle contenue dans la date d'inscription tout en la rendant exploitable par les modèles.

Transformation appliquée :

- Conversion de **RegistrationDate** en format date.
- Extraction de **RegYear**, **RegMonth**, **RegDay** et **RegWeekday**.
- Suppression de la colonne originale **RegistrationDate**.

4.5 Feature engineering sur l'adresse IP

La variable **LastLoginIP** contient l'adresse IP utilisée lors de la dernière connexion du client. Sous sa forme brute, cette variable n'est pas directement exploitable par les modèles Machine Learning, car elle est représentée sous forme textuelle et possède une forte cardinalité.

Afin de rendre cette information utilisable, un feature engineering a été appliqué sur la colonne **LastLoginIP**. L'objectif est d'extraire des informations simples et numériques à partir de l'adresse IP.

Deux nouvelles variables ont été créées :

- **IP_FirstOctet** : premier octet de l'adresse IP ;
- **IP_IsPrivate** : indique si l'adresse IP est privée ou publique.

La variable **IP_FirstOctet** permet de conserver une information partielle sur la plage réseau de l'adresse IP. La variable **IP_IsPrivate** est une variable binaire indiquant si l'adresse IP appartient à un réseau privé.

Transformation appliquée :

- Extraction du premier octet de **LastLoginIP**.
- Détection du caractère privé ou public de l'adresse IP.
- Suppression de la colonne brute **LastLoginIP**.

4.6 Suppression des colonnes inutiles ou risquées

Certaines colonnes de la dataset ne sont pas pertinentes pour l'apprentissage ou peuvent introduire un biais dans les modèles. Elles ont donc été supprimées avant la phase de modélisation.

Les colonnes supprimées sont :

- `CustomerID`;
- `NewsletterSubscribed`;
- `ChurnRiskCategory`.

La justification de cette suppression est la suivante :

- `CustomerID` : il s'agit uniquement d'un identifiant client. Cette variable ne contient pas d'information comportementale utile pour les modèles.
- `NewsletterSubscribed` : cette variable est constante dans la dataset, elle n'apporte donc aucune information discriminante.
- `ChurnRiskCategory` : cette variable est fortement liée à la cible `Churn`. Son utilisation pourrait provoquer un risque de *data leakage*, c'est-à-dire une fuite d'information de la variable cible vers les features.

Décision de preprocessing : les colonnes `CustomerID`, `NewsletterSubscribed` et `ChurnRiskCategory` ont été supprimées afin d'améliorer la qualité des données et de limiter le risque de biais dans les modèles.

4.7 Encodage et normalisation

Après le nettoyage des données, les variables doivent être transformées dans un format exploitable par les modèles Machine Learning. En effet, les algorithmes ne peuvent pas traiter directement les variables catégorielles sous forme textuelle, et certaines méthodes sont sensibles aux différences d'échelle entre les variables numériques.

Deux traitements principaux ont donc été appliqués :

- **One-Hot Encoding** pour les variables catégorielles ;
- **StandardScaler** pour les variables numériques.

Le *One-Hot Encoding* permet de transformer chaque modalité catégorielle en une variable binaire. Par exemple, une variable comme `Gender` peut être transformée en plusieurs colonnes telles que `Gender_M`, `Gender_F` ou `Gender_Unknown`.

La normalisation avec **StandardScaler** permet de centrer et réduire les variables numériques afin d'obtenir une moyenne proche de 0 et un écart-type proche de 1. Cette étape est importante pour les modèles sensibles à l'échelle des données, comme la régression logistique, l'ACP ou certains algorithmes basés sur les distances.

Une attention particulière a été portée à l'ordre d'application des transformations :

- `fit_transform` est appliqué uniquement sur `X_train`;
- `transform` est appliqué sur `X_test`.

Cette méthode permet d'éviter le *data leakage*, car les informations du jeu de test ne sont pas utilisées pendant l'apprentissage du preprocessing.

Pipeline de transformation :

- Variables numériques : imputation par médiane + **StandardScaler**.
- Variables catégorielles : imputation par modalité fréquente + **OneHotEncoder**.
- Apprentissage des transformations uniquement sur `X_train`.
- Application des mêmes transformations sur `X_test`.

4.8 Split train/test

Après le nettoyage, l'encodage et la normalisation des données, la dataset a été divisée en deux ensembles : un ensemble d'entraînement et un ensemble de test.

Le découpage appliqué est le suivant :

- 80% des données pour l'entraînement ;
- 20% des données pour le test.

L'ensemble d'entraînement est utilisé pour apprendre les modèles, tandis que l'ensemble de test permet d'évaluer leurs performances sur des données jamais vues.

Une stratification a été appliquée selon la variable cible **Churn**. Cette stratégie permet de conserver la même proportion de clients fidèles et de clients partis dans les deux ensembles.

Découpage utilisé :

- `train_size = 80%`
- `test_size = 20%`
- `stratify = Churn`

Cette étape garantit une évaluation plus fiable des modèles de classification, en conservant une distribution équilibrée de la variable cible entre les ensembles d'entraînement et de test.

La figure suivante résume les principales étapes du pipeline de preprocessing appliqué dans ce projet.



FIGURE 11 – Pipeline de preprocessing

5 Transformation par ACP / PCA

5.1 Objectif de l'ACP

L'Analyse en Composantes Principales, appelée également ACP ou PCA, est une méthode de réduction de dimension. Elle permet de transformer un grand nombre de variables en un nombre plus réduit de composantes principales tout en conservant une grande partie de l'information présente dans les données.

Dans ce projet, l'ACP est appliquée après le preprocessing, c'est-à-dire après le nettoyage, l'encodage et la normalisation des données. Cette étape est importante car les données contiennent de nombreuses variables, notamment après l'encodage One-Hot des variables catégorielles.

Les objectifs principaux de l'ACP sont les suivants :

- réduire la dimension du dataset ;
- conserver l'information principale contenue dans les variables ;
- faciliter la visualisation des clients en deux dimensions ;
- réduire le bruit présent dans les données ;
- comparer les performances des modèles avec et sans PCA.

Ainsi, l'ACP permet d'obtenir une représentation plus compacte des données tout en gardant les informations les plus importantes pour les étapes de modélisation.

5.2 Application de PCA

L'ACP a été appliquée après la phase de preprocessing, c'est-à-dire après le nettoyage des données, l'imputation des valeurs manquantes, l'encodage des variables catégorielles et la normalisation des variables numériques.

Cette étape a été réalisée uniquement sur les données déjà transformées afin de garantir que toutes les variables soient numériques et comparables entre elles.

La démarche suivie est la suivante :

- entraînement de la PCA sur `X_train`;
- transformation de `X_train` avec `fit_transform`;
- transformation de `X_test` avec `transform`.

L'application de `fit_transform` uniquement sur `X_train` permet d'éviter le *data leakage*. En effet, les informations du jeu de test ne doivent pas être utilisées lors de l'apprentissage des composantes principales.

Principe appliqué :

- `PCA.fit_transform(X_train)` : apprentissage et transformation sur les données d'entraînement.
- `PCA.transform(X_test)` : transformation du jeu de test avec les mêmes composantes.

Cette approche garantit une comparaison correcte entre les modèles entraînés avec les données originales prétraitées et ceux entraînés avec les données réduites par PCA.

5.3 Analyse de la variance expliquée

Après l'application de l'ACP, une analyse de la variance expliquée a été réalisée afin de déterminer le nombre de composantes principales à conserver.

La variance expliquée indique la quantité d'information capturée par chaque composante principale. Les premières composantes expliquent généralement une grande partie de l'information, tandis que les composantes suivantes apportent progressivement moins d'information.

Deux analyses ont été réalisées :

- la variance expliquée par chaque composante ;
- la variance expliquée cumulée.

La variance expliquée cumulée permet de choisir un nombre de composantes suffisant pour conserver une proportion importante de l'information initiale. Dans ce projet, une version des données conservant **80% de la variance** a été générée afin de réduire la dimension tout en gardant l'essentiel de l'information.




FIGURE 12 – Variance expliquée par chaque composante PCA

La figure précédente montre la contribution individuelle de chaque composante principale. Elle permet d'observer que les premières composantes portent la majorité de l'information.




FIGURE 13 – Variance expliquée cumulée par PCA

La figure de variance cumulée permet d'identifier le nombre minimal de composantes nécessaires pour atteindre un seuil donné, par exemple 80% ou 90% de variance conservée.

Enfin, une visualisation en deux dimensions a été réalisée à partir des deux premières composantes principales afin d'observer la distribution des clients selon la variable cible **Churn**.




FIGURE 14 – Visualisation PCA 2D selon Churn

Cette visualisation permet d’observer si les clients fidèles et les clients ayant quitté l’entreprise présentent une séparation visible dans l’espace réduit à deux dimensions. Même si deux composantes ne capturent pas toute l’information, elles permettent une première interprétation visuelle de la structure des données.

6 Modélisation

La phase de modélisation constitue le cœur du projet Machine Learning. Elle permet d’exploiter les données préparées afin de répondre aux objectifs métier définis au début du projet.

Dans ce travail, trois approches de modélisation ont été appliquées :

- **Clustering** : segmenter les clients selon leurs comportements ;
- **Classification** : prédire le risque de churn ;
- **Régression** : estimer la valeur monétaire des clients.

Ces trois approches sont complémentaires. Le clustering permet de mieux comprendre les groupes de clients, la classification permet d’anticiper le départ des clients, et la régression permet d’estimer leur valeur économique.

6.1 Clustering : segmentation des clients

6.1.1 Objectif

Le clustering est une méthode d’apprentissage non supervisé. Son objectif est de regrouper automatiquement les clients en segments homogènes selon leurs caractéristiques et leurs comportements, sans utiliser la variable cible **Churn** pendant l’apprentissage.

Dans ce projet, le clustering permet d’identifier des groupes de clients similaires à partir des variables disponibles après preprocessing. Cette segmentation peut ensuite être analysée afin de comprendre quels groupes présentent un risque de churn plus élevé.

L'intérêt du clustering dans ce contexte est de :

- découvrir des profils clients sans utiliser de labels ;
- identifier des segments homogènes ;
- analyser le taux de churn dans chaque segment après la création des clusters ;
- proposer des actions marketing adaptées à chaque groupe.

Ainsi, le clustering permet de passer d'une vision globale de la clientèle à une vision segmentée, plus utile pour la prise de décision marketing.

6.1.2 Méthode utilisée

Pour réaliser la segmentation des clients, l'algorithme **KMeans** a été utilisé. KMeans est une méthode de clustering qui cherche à regrouper les observations en un nombre fixe de clusters, de manière à ce que les clients d'un même cluster soient les plus similaires possible.

Le principe de KMeans consiste à :

- choisir un nombre de clusters k ;
- initialiser les centres des clusters ;
- affecter chaque client au centre le plus proche ;
- mettre à jour les centres des clusters ;
- répéter le processus jusqu'à stabilisation.

Afin de choisir le nombre optimal de clusters, deux méthodes ont été utilisées :

- **Méthode du coude** : permet d'observer l'évolution de l'inertie selon le nombre de clusters.
- **Silhouette score** : permet d'évaluer la qualité de séparation entre les clusters.

La méthode du coude aide à identifier un point à partir duquel l'ajout de nouveaux clusters n'améliore plus significativement l'inertie. Le silhouette score, quant à lui, mesure à quel point les clusters sont bien séparés et cohérents.

6.1.3 Choix du nombre de clusters

Le choix du nombre de clusters est une étape importante dans l'application de l'algorithme KMeans. Dans ce projet, deux méthodes ont été utilisées pour guider ce choix : la méthode du coude et le score silhouette.

Après analyse des résultats, le nombre de clusters retenu est :

Nombre de clusters retenu : $k = 3$

La figure suivante présente la méthode du coude, qui permet d'observer l'évolution de l'inertie selon le nombre de clusters.




FIGURE 15 – Méthode du coude

La figure suivante présente l'évolution du score silhouette selon le nombre de clusters.




FIGURE 16 – Score silhouette selon le nombre de clusters

D'après les résultats obtenus, $k = 2$ présente le meilleur score silhouette. Cependant, cette segmentation reste trop simple d'un point de vue métier, car elle tend à séparer les clients uniquement en deux grands groupes.

Le choix de $k = 3$ a donc été retenu comme un meilleur compromis entre qualité statistique et interprétation métier. Il permet d'obtenir une segmentation plus riche, avec trois profils de clients distincts. Au-delà de trois clusters, le score silhouette chute fortement, ce qui indique une dégradation

de la qualité de séparation entre les groupes.

Ainsi, le nombre de clusters retenu pour la suite de l'analyse est $k = 3$.

6.1.4 Résultats du clustering

Après l'application de l'algorithme KMeans avec $k = 3$, les clusters obtenus ont été analysés en calculant le taux de churn associé à chaque groupe. Cette analyse permet d'interpréter chaque segment client du point de vue métier.

Le tableau suivant résume les principaux résultats du clustering :

TABLE 2 – Résultats du clustering

Cluster	Taux de churn	Interprétation
Cluster 0	33.39%	Clients standards / risque moyen
Cluster 1	0.00%	Clients fidèles
Cluster 2	50.00%	Clients à haut risque

Ces résultats montrent que les trois clusters présentent des profils très différents :

- **Cluster 1** : ce groupe présente un taux de churn nul. Il correspond donc à des clients fidèles et engagés.
- **Cluster 0** : ce groupe présente un taux de churn intermédiaire, proche du taux global de la dataset. Il peut être interprété comme un segment de clients standards ou à risque moyen.
- **Cluster 2** : ce groupe présente le taux de churn le plus élevé, soit 50%. Il s'agit donc d'un segment à haut risque, qui doit être ciblé en priorité par les actions de rétention.

La figure suivante représente visuellement le taux de churn observé dans chaque cluster.




FIGURE 17 – Taux de churn par cluster

Cette visualisation met en évidence les différences de risque entre les segments, et confirme que le clustering permet de distinguer des groupes de clients ayant des comportements différents vis-à-vis du churn.

Enfin, une visualisation des clusters projetés sur les deux premières composantes principales a été réalisée à l'aide de la PCA.




FIGURE 18 – Visualisation des clusters avec PCA

Cette représentation en deux dimensions permet d’observer la structure globale des clusters et la manière dont les clients se répartissent dans l’espace réduit par la PCA. Elle offre une interprétation visuelle complémentaire de la segmentation obtenue.

6.2 Classification : prédiction du churn

6.2.1 Objectif

La classification est une approche d’apprentissage supervisé qui consiste à prédire une catégorie à partir des caractéristiques disponibles dans la dataset.

Dans ce projet, l’objectif de la classification est de prédire si un client risque de quitter l’entreprise ou non. Cette information est particulièrement importante pour l’entreprise, car elle permet d’anticiper le départ des clients et de mettre en place des actions de rétention adaptées.

La variable cible utilisée est :

Variable cible : Churn

La variable **Churn** possède deux classes :

- **Churn** = 0 : client fidèle ;
- **Churn** = 1 : client parti.

Ainsi, le modèle de classification permet d’identifier les clients à risque afin de proposer des campagnes marketing ciblées avant leur départ.

6.2.2 Modèles testés

Afin de prédire la variable cible **Churn**, plusieurs modèles de classification ont été testés et comparés. L’objectif est d’évaluer l’impact du choix du modèle ainsi que l’impact de la réduction de dimension par PCA sur les performances.

Les modèles testés sont les suivants :

- **Logistic Regression sans PCA** ;
- **Random Forest sans PCA** ;
- **Logistic Regression avec PCA** ;
- **Random Forest avec PCA**.

Les modèles sans PCA utilisent directement les données prétraitées, encodées et normalisées. Les modèles avec PCA utilisent une version réduite des données conservant environ **80% de la variance**.

Objectif de la comparaison : analyser si la réduction de dimension par PCA améliore ou réduit les performances des modèles de classification.

6.2.3 Métriques utilisées

Pour évaluer les performances des modèles de classification, plusieurs métriques ont été utilisées. Ces métriques permettent d'analyser la qualité des prédictions sous différents angles.

Les métriques utilisées sont les suivantes :

- **Accuracy** : proportion totale de prédictions correctes.
- **Precision** : proportion de clients prédits comme churn qui sont réellement des clients churn.
- **Recall** : proportion de clients churn correctement détectés par le modèle.
- **F1-score** : moyenne harmonique entre la précision et le rappel.
- **ROC-AUC** : capacité du modèle à distinguer les deux classes.

Dans le contexte de la prédiction du churn, le **recall** est particulièrement important, car l'objectif est d'identifier le maximum de clients à risque afin de pouvoir agir avant leur départ.

Remarque : Le **F1-score** est utilisé comme critère global important, car il équilibre la précision et le rappel, ce qui est utile dans un problème de classification comme le churn.

6.2.4 Résultats

Les modèles de classification ont été entraînés et évalués sur le jeu de test. Les résultats obtenus permettent de comparer les performances des modèles avec et sans réduction de dimension par PCA.

Le tableau suivant présente les résultats comparatifs des modèles de classification selon les métriques utilisées.

TABLE 3 – Résultats comparatifs des modèles de classification

Modèle	Accuracy	Precision	Recall	F1-score	ROC-AUC
Logistic Regression sans PCA	0.9977	0.9966	0.9966	0.9966	0.9998
Random Forest sans PCA	1.0000	1.0000	1.0000	1.0000	1.0000
Logistic Regression avec PCA	0.9646	0.9452	0.9485	0.9468	0.9928
Random Forest avec PCA	0.9600	0.9923	0.8866	0.9365	0.9871

D'après ces résultats, le modèle **Random Forest sans PCA** obtient les meilleures performances sur l'ensemble des métriques. Les modèles sans PCA présentent globalement de meilleurs scores que les modèles avec PCA, ce qui indique que la réduction de dimension peut entraîner une perte d'information utile pour la classification.

La figure suivante présente une comparaison visuelle des performances des différents modèles de classification.




FIGURE 19 – Comparaison des modèles de classification

6.2.5 Interprétation

Les résultats obtenus montrent que le modèle **Random Forest sans PCA** présente les meilleures performances parmi les modèles testés. Il obtient des scores parfaits sur l'ensemble des métriques : Accuracy, Precision, Recall, F1-score et ROC-AUC.

Cependant, ces résultats doivent être interprétés avec prudence. Dans un contexte réel, des scores parfaitement égaux à 1 peuvent indiquer que certaines variables de la dataset sont très fortement liées à la variable cible **Churn**. Cela peut également révéler un risque de *data leakage*, c'est-à-dire une fuite d'information de la cible vers les variables explicatives.

Certaines variables catégorielles, comme **CustomerType**, **RFMSegment** ou **AccountStatus**, peuvent contenir une information très proche du churn. Elles peuvent donc faciliter fortement la tâche du modèle et expliquer les performances très élevées obtenues.

Conclusion : Le modèle **Random Forest sans PCA** est retenu comme meilleur modèle de classification. Néanmoins, ses scores parfaits nécessitent une validation supplémentaire afin de vérifier l'absence de variables trop explicatives ou de *data leakage*.

6.3 Régression : prédiction de MonetaryTotal

6.3.1 Objectif

La régression est une approche d'apprentissage supervisé utilisée pour prédire une valeur numérique continue. Contrairement à la classification, qui prédit une classe, la régression permet d'estimer une quantité.

Dans ce projet, l'objectif de la régression est de prédire le montant total dépensé par un client. Cette information peut être utile pour estimer la valeur client et aider l'entreprise à prioriser ses actions marketing.

La variable cible utilisée est :

Variable cible : MonetaryTotal

Ainsi, le modèle de régression permet d'estimer la valeur monétaire potentielle d'un client à partir de ses caractéristiques comportementales, transactionnelles et démographiques.

6.3.2 Modèles testés

Afin de prédire la variable cible **MonetaryTotal**, deux modèles de régression ont été testés et comparés. L'objectif est d'évaluer leur capacité à estimer le montant total dépensé par un client à partir des variables disponibles.

Les modèles testés sont les suivants :

- **Linear Regression** ;
- **Random Forest Regressor**.

La **Linear Regression** permet de modéliser une relation linéaire entre les variables explicatives et la valeur monétaire du client. Le **Random Forest Regressor**, quant à lui, est un modèle basé sur plusieurs arbres de décision, capable de capturer des relations plus complexes et non linéaires.

Objectif de la comparaison : identifier le modèle le plus performant pour estimer la valeur monétaire totale des clients.

6.3.3 Métriques utilisées

Pour évaluer les performances des modèles de régression, plusieurs métriques ont été utilisées. Ces métriques permettent de mesurer l'écart entre les valeurs réelles de **MonetaryTotal** et les valeurs prédites par les modèles.

Les métriques utilisées sont les suivantes :

- **MAE** : erreur absolue moyenne entre les valeurs réelles et les valeurs prédites.
- **RMSE** : racine de l'erreur quadratique moyenne, plus sensible aux grandes erreurs.
- **R²** : proportion de la variance de la variable cible expliquée par le modèle.

Le **MAE** permet d'avoir une idée de l'erreur moyenne globale du modèle. Le **RMSE** pénalise davantage les grandes erreurs, ce qui est important lorsque certaines valeurs de **MonetaryTotal** sont très élevées. Enfin, le **R²** indique la capacité du modèle à expliquer les variations de la variable cible.

Critère de sélection : dans ce projet, le modèle de régression est principalement choisi selon le **RMSE** le plus faible et le **R²** le plus élevé.

6.3.4 Résultats

Les modèles de régression ont été entraînés afin de prédire la variable **MonetaryTotal**. Les performances ont ensuite été évaluées à l'aide des métriques **MAE**, **RMSE** et **R²**.

Le tableau suivant présente les résultats comparatifs des modèles de régression.

TABLE 4 – Résultats comparatifs des modèles de régression

Modèle	MAE	RMSE	R ²
Linear Regression	840.51	6603.90	0.661
Random Forest Regressor	741.02	7342.25	0.581

D'après ces résultats, le modèle **Random Forest Regressor** obtient un meilleur **MAE**, ce qui signifie qu'il produit en moyenne une erreur absolue plus faible. Cependant, le modèle **Linear Regression** obtient un meilleur **RMSE** ainsi qu'un meilleur **R²**. Cela indique qu'il est plus stable face aux grandes erreurs et qu'il explique une plus grande partie de la variance de **MonetaryTotal**.

La figure suivante présente une comparaison des erreurs MAE et RMSE pour les deux modèles de régression.




FIGURE 20 – Comparaison MAE / RMSE des modèles de régression

La figure suivante compare les valeurs de R^2 obtenues par les modèles.




FIGURE 21 – Comparaison du R^2 des modèles de régression

6.3.5 Interprétation

Les résultats de la régression montrent que les deux modèles présentent des performances différentes selon la métrique utilisée.

Le modèle **Random Forest Regressor** obtient un meilleur MAE. Cela signifie qu'il réalise, en moyenne, des erreurs absolues plus faibles sur les observations standards. Il peut donc être plus performant pour prédire les clients ayant des comportements proches de la majorité des données.

Cependant, le modèle **Linear Regression** obtient un meilleur RMSE ainsi qu'un meilleur R^2 . Le RMSE étant plus sensible aux grandes erreurs, cela indique que la régression linéaire gère mieux les prédictions sur l'ensemble du jeu de test, notamment pour les valeurs plus extrêmes de **MonetaryTotal**. De plus, son R^2 plus élevé montre qu'elle explique une plus grande partie de la variance de la variable cible.

Conclusion : Même si le **Random Forest Regressor** présente un meilleur MAE, le modèle **Linear Regression** est retenu comme modèle global le plus stable, car il obtient un meilleur RMSE et un meilleur R^2 .

7 Évaluation globale et recommandations métier

7.1 Synthèse des résultats

Après les différentes étapes de modélisation, une évaluation globale a été réalisée afin de résumer les résultats obtenus pour les trois approches utilisées : le clustering, la classification et la régression.

Les principaux résultats sont les suivants :

- **Clustering :** la segmentation des clients a été réalisée avec KMeans en retenant $k = 3$ clusters.
- **Classification :** le meilleur modèle pour prédire le churn est **Random Forest sans PCA**.
- **Régression :** le meilleur modèle global pour prédire **MonetaryTotal** est **Linear Regression**.

Le tableau suivant présente une synthèse des meilleurs modèles retenus pour chaque tâche.

TABLE 5 – Synthèse des meilleurs modèles

Tâche	Meilleur modèle	Critère principal
Clustering	KMeans, $k = 3$	Silhouette score + interprétation métier
Classification	Random Forest sans PCA	F1-score / ROC-AUC
Régression	Linear Regression	RMSE / R^2

Cette synthèse montre que chaque approche apporte une information complémentaire. Le clustering permet de segmenter les clients, la classification permet d'anticiper le churn, et la régression permet d'estimer la valeur monétaire des clients.

Remarque : bien que le modèle Random Forest sans PCA obtienne les meilleurs résultats en classification, ses scores parfaits doivent être interprétés avec prudence, car ils peuvent indiquer la présence de variables très fortement liées au churn.

7.2 Recommandations métier

À partir des résultats obtenus lors des phases de clustering, de classification et de régression, plusieurs recommandations métier peuvent être proposées afin d'aider l'entreprise à améliorer ses décisions marketing.

7.2.1 Recommandation 1 : Cibler les clients à haut risque

Le **cluster 2** présente le taux de churn le plus élevé. Il doit donc être considéré comme prioritaire dans les actions marketing.

Les actions recommandées sont les suivantes :

- cibler en priorité les clients du **cluster 2**;
- lancer des campagnes de rétention ;
- proposer des offres personnalisées afin de limiter le départ des clients.

7.2.2 Recommandation 2 : Valoriser les clients fidèles

Le **cluster 1** regroupe les clients les plus fidèles, avec un taux de churn nul. Ces clients représentent une valeur importante pour l'entreprise et doivent être fidélisés sur le long terme.

Les actions recommandées sont :

- mettre en place un programme VIP ;
- proposer des récompenses de fidélité ;
- encourager les achats répétés par des avantages exclusifs.

7.2.3 Recommandation 3 : Utiliser la classification pour anticiper le churn

Le modèle de classification permet d'identifier les clients présentant un risque de départ avant qu'ils ne quittent réellement l'entreprise.

Les actions possibles sont :

- identifier automatiquement les clients à risque ;
- déclencher des actions préventives avant leur départ ;
- personnaliser les messages marketing selon le niveau de risque.

7.2.4 Recommandation 4 : Utiliser la régression pour prioriser la valeur client

Le modèle de régression permet d'estimer la valeur monétaire d'un client à travers la variable **MonetaryTotal**. Cette estimation peut être utilisée pour mieux répartir les ressources marketing.

Les actions recommandées sont :

- cibler les clients à forte valeur ;
- adapter les budgets marketing selon la valeur estimée des clients ;
- accorder une attention particulière aux clients à la fois rentables et à risque.

7.2.5 Recommandation 5 : Surveiller le data leakage

Certaines variables semblent très fortement liées à la variable cible **Churn**. Il est donc important de vérifier que les performances élevées obtenues ne proviennent pas d'une fuite d'information.

Les actions recommandées sont :

- vérifier les variables trop liées au churn ;
- refaire une expérience sans les variables suspectes ;
- comparer les performances avant et après suppression de ces variables.

Idée clé : la combinaison du clustering, de la classification et de la régression permet de transformer les résultats des modèles en recommandations marketing concrètes et exploitables.

La figure suivante résume les principales sources d'information utilisées pour produire les recommandations métier.




FIGURE 22 – Schéma des recommandations métier

8 Limites du projet

Malgré les résultats obtenus, certaines limites doivent être prises en considération afin d'interpréter correctement les performances des modèles.

- **Dataset pédagogique** : la base de données utilisée est conçue dans un cadre pédagogique. Elle peut donc être simplifiée par rapport à des données réelles issues d'un environnement e-commerce complet.
- **Scores de classification très élevés** : certains modèles, notamment le **Random Forest sans PCA**, obtiennent des scores presque parfaits. Cela peut indiquer que certaines variables sont très fortement liées à la variable cible **Churn**.
- **Risque de data leakage** : la présence de variables trop explicatives peut provoquer une fuite d'information entre les features et la variable cible. Ce risque doit être vérifié avant une utilisation réelle du modèle.
- **Présence d'outliers dans MonetaryTotal** : la variable monétaire contient des valeurs extrêmes pouvant influencer les performances des modèles de régression.
- **Sensibilité de la régression aux valeurs extrêmes** : les modèles de régression peuvent produire des erreurs importantes pour certains clients atypiques ou ayant des montants très élevés.
- **Validation sur données futures** : les modèles doivent être testés sur de nouvelles données réelles afin de confirmer leur robustesse et leur capacité de généralisation.

Remarque : Les résultats obtenus sont encourageants, mais ils doivent être interprétés avec prudence. Une validation supplémentaire sur des données réelles et récentes est nécessaire avant tout déploiement opérationnel.

9 Conclusion générale

Ce projet a permis de mettre en œuvre une chaîne complète de Machine Learning appliquée à l'analyse comportementale client dans un contexte e-commerce. L'objectif principal était d'exploiter les données clients afin de mieux comprendre leurs comportements, de segmenter la clientèle, de prédire le churn et d'estimer la valeur monétaire des clients.

Les différentes étapes du projet ont couvert l'ensemble du processus Machine Learning :

- l'exploration et l'analyse de la qualité des données ;
- le nettoyage, l'encodage et la normalisation des features ;
- la réduction de dimension par ACP ;

- la modélisation avec clustering, classification et régression ;
- l'évaluation des résultats et l'interprétation métier.

Les résultats obtenus montrent que les données clients peuvent être exploitées pour produire des informations utiles à la prise de décision. Le clustering a permis d'identifier différents segments de clients, la classification a permis de prédire les clients à risque de churn, et la régression a permis d'estimer la valeur monétaire des clients.

Sur le plan métier, ces résultats peuvent aider l'entreprise à améliorer la rétention client, personnaliser les campagnes marketing et prioriser les clients à forte valeur. Cependant, certaines limites doivent être prises en compte, notamment le risque de data leakage, les scores de classification très élevés et l'influence des valeurs extrêmes sur la régression.

En conclusion, ce projet montre comment une approche Machine Learning bien structurée peut transformer des données clients en recommandations marketing exploitables et en décisions plus efficaces pour l'entreprise.

Conclusion finale : Une chaîne Machine Learning complète permet de passer des données brutes à des insights métier concrets, utiles pour anticiper le churn, segmenter les clients et optimiser les stratégies marketing.